

Deteksi Perilaku Berisiko pada Pengemudi Roda Empat Menggunakan YOLO (You Only Look Once) v10 untuk Meningkatkan Keamanan Berkendara

Sendi Satria Pangestu¹, Mutia Fadhilla²

Prodi Teknik Informatika, Universitas Islam Riau² (10 pt)
sendisatriapangestu@student.uir.ac.id¹, tiafadhilla@eng.uir.ac.id²

Article Info

Article history:

Dikirim Juli 2025
Direvisi Juli 2025
Diterima Juli 2025

Keyword:

Perilaku Mengemudi Berisiko
Deep Learning
YOLOv10
Keselamatan Berkendara
Computer Vision

ABSTRAK

Penelitian ini bertujuan untuk mengembangkan sistem deteksi perilaku berisiko pada pengemudi kendaraan roda empat menggunakan metode YOLOv10n. Sistem ini dirancang untuk mendeteksi empat perilaku yang berpotensi membahayakan keselamatan berkendara, yaitu eating/drinking, phone use, smoking, dan sleeping. Dataset yang digunakan berasal dari kombinasi video pengawasan kabin yang direkam sendiri dan dataset open-source dari Roboflow, dengan mempertimbangkan kondisi pencahayaan (terang, redup, malam) serta sudut pandang kamera (depan dan samping). Selain itu, dilakukan perbandingan performa model YOLOv10n dengan YOLOv5n dan YOLOv8n dari segi akurasi, kecepatan, dan efisiensi ukuran model. Hasil evaluasi menunjukkan bahwa YOLOv10n memberikan performa terbaik dengan nilai mAP@0.5 sebesar 93.1%, mAP@0.5:0.95 sebesar 54.8%, precision sebesar 0.905, recall sebesar 0.865, kecepatan inferensi 208 FPS, dan ukuran model hanya 4.6 MB. Dengan performa tersebut, YOLOv10n dinilai layak untuk diterapkan pada sistem pendeteksi perilaku pengemudi secara real-time, terutama pada perangkat dengan keterbatasan memori dan daya komputasi.

© This work is licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.

Corresponding Author:

Muthia Fadhila
Program Studi Teknik Informatika, Fakultas Teknik
Universitas Islam Riau,
Jl. Kaharudin Nst No.113, Simpang Tiga, Kecamatan. Bukit Raya, Kota Pekanbaru, Riau 28284
Email: tiafadhilla@eng.uir.ac.id

1. Pendahuluan

Keselamatan berkendara menjadi salah satu aspek krusial dalam sistem transportasi, terutama di Indonesia yang memiliki tingkat kecelakaan lalu lintas cukup tinggi. Berdasarkan data Badan Pusat Statistik (BPS) tahun 2023, tercatat sebanyak 152.008 kasus kecelakaan lalu lintas dengan korban meninggal dunia sebanyak 27.895 jiwa [1]. Sebagian besar insiden tersebut terjadi akibat kelalaian manusia, termasuk perilaku berisiko saat mengemudi seperti menggunakan ponsel, mengantuk, merokok, serta makan dan minum di dalam kendaraan [2].

Perilaku-perilaku tersebut sulit dideteksi secara manual dan real-time, terutama dalam skala besar [3]. Oleh karena itu, dibutuhkan sistem otomatis berbasis kecerdasan buatan yang mampu mendeteksi perilaku pengemudi melalui video pengawasan atau kamera kabin kendaraan. Salah satu

metode yang banyak digunakan dalam sistem deteksi visual adalah YOLO (You Only Look Once), yang telah berkembang dalam berbagai versi, mulai dari YOLOv1 hingga YOLOv10 [4].

YOLOv10 hadir dengan arsitektur yang lebih efisien, mampu melakukan deteksi real-time pada perangkat edge seperti Raspberry Pi, Jetson Nano, atau kamera cerdas (smart camera) [5]. Dibandingkan dengan pendahulunya, YOLOv10 mengedepankan keseimbangan antara akurasi dan ukuran model yang ringan, sehingga cocok untuk implementasi di lapangan [6].

Penelitian ini bertujuan untuk merancang dan mengevaluasi model deteksi perilaku pengemudi menggunakan YOLOv10n dengan fokus pada empat jenis perilaku berisiko. Selain itu, dilakukan pula perbandingan performa model dengan YOLOv5n dan YOLOv8n berdasarkan hasil pelatihan dan pengujian pada dataset yang dikumpulkan dari video nyata dan sumber terbuka.

2. Metode Penelitian

Metodologi penelitian ini dirancang secara sistematis untuk memastikan bahwa setiap tahapan yang dilakukan dapat menghasilkan model deteksi perilaku berisiko pengemudi yang akurat dan efisien. Penelitian dimulai dari proses pengumpulan data berupa video pengemudi yang menunjukkan berbagai jenis perilaku berisiko. Kemudian dilakukan proses pelabelan dan pelatihan model dengan pendekatan deep learning menggunakan algoritma YOLO pada tiga versi berbeda (YOLOv5n, YOLOv8n, dan YOLOv10n). Evaluasi dilakukan berdasarkan metrik performa deteksi objek yang umum digunakan dalam computer vision. Rincian tiap tahap dijelaskan sebagai berikut

2.1 Tahapan Penelitian

Penelitian ini dilakukan melalui beberapa tahapan: pengumpulan data video, preprocessing data, pelabelan, pelatihan model deteksi menggunakan YOLOv10n, evaluasi performa model, dan analisis hasil. Arsitektur sistem dan alur kerja dibuat untuk menggambarkan proses deteksi perilaku berisiko dari input video hingga output klasifikasi perilaku.

2.2 Pengumpulan dan Persiapan Data

Dataset yang digunakan merupakan gabungan dari video hasil rekaman langsung (real capture) dan dataset open-source dari Roboflow. Video direkam dalam berbagai kondisi pencahayaan (terang, redup, malam) serta dari dua sudut pandang kamera, yaitu depan dan samping. Setiap video dipotong menjadi frame dan dilakukan proses pelabelan manual menggunakan LabelImg.

Empat kelas perilaku yang digunakan yaitu:

- **Eating/Drinking:** Mengonsumsi makanan atau minuman saat berkendara.
- **Phone Use:** Menggunakan ponsel dalam bentuk apapun (telepon, mengetik, melihat layar).
- **Smoking:** Merokok sambil mengemudi.
- **Sleeping:** Tertidur atau menunjukkan tanda-tanda mengantuk berat.

2.3 Pelatihan Model YOLO

Tiga model dibandingkan dalam penelitian ini: YOLOv5n, YOLOv8n, dan YOLOv10n. Semua model dilatih menggunakan Google Colab dengan GPU Tesla T4. Proses pelatihan dilakukan menggunakan optimizer AdamW [7], untuk melihat pengaruhnya terhadap konvergensi dan akurasi model.

Augmentasi data juga diterapkan pada dataset agar model dapat mengenali variasi kondisi pencahayaan, sudut pandang, dan ekspresi pengemudi [8]. Parameter pelatihan disesuaikan agar adil antar model: jumlah epoch 50, batch size 16, dan learning rate awal 0.01.

2.4 Evaluasi Model

Model dievaluasi menggunakan metrik berikut:

- **Precision:** Proporsi prediksi positif yang benar.
- **Recall:** Kemampuan model mendeteksi seluruh objek relevan.
- **mAP@0.5 dan mAP@0.5:0.95:** Ukuran rata-rata presisi untuk threshold IoU yang berbeda.
- **FPS (Frame per Second):** Kecepatan inferensi.
- **Ukuran model:** Untuk mengukur efisiensi dan potensi deployment ke perangkat embedded.

3. Hasil dan Analisis

3.1 Hasil Uji

Untuk mengetahui performa dari masing-masing model (YOLOv5n, YOLOv8n, YOLOv10n), dilakukan pelatihan menggunakan optimizer AdamW dengan dua skema pembagian data:

- Skema 1: 80% data latih dan 20% data validasi.
- Skema 2: 70% data latih, 10% data validasi, dan 20% data uji.

Evaluasi dilakukan berdasarkan mAP, precision, recall, kecepatan inferensi (FPS), dan efisiensi ukuran model. Hasil lengkap ditampilkan pada Tabel 1 berikut.

Table 1. Perbandingan Performansi Model YOLO pada Dua Skema Pembagian Data

Model	Skema	Precision	Recall	mAP@0.5	mAP@0.5:0.95	FPS	Ukuran Model (KB)
YOLOv5n	1	93.5%	75.9%	86.9%	45.5%	125	5046
YOLOv8n	1	90.5%	81.1%	89.9%	44.6%	135	6014
YOLOv10n	1	88.6%	77.2%	86.3%	44.4%	196	4650
YOLOv5n	2	93.7%	88.1%	94.7%	56.0%	147	5048
YOLOv8n	2	95.4%	87.1%	92.9%	56.0%	172	6016
YOLOv10n	2	90.5%	86.5%	93.1%	54.8%	208	4602

YOLOv10n berhasil mendeteksi objek perilaku dengan akurasi tinggi dalam waktu yang sangat cepat, menjadikannya cocok untuk sistem monitoring real-time. YOLOv5n dan YOLOv8n masing-masing memiliki performa cukup baik, namun kalah dalam hal efisiensi ukuran model dan kecepatan inferensi.

3.2 Analisis Perilaku per Kelas

Performa model deteksi dievaluasi lebih lanjut berdasarkan empat kategori perilaku: drinking and eating, phone use, smoking, dan sleeping.

Table 2. Perbandingan detail performa class model pada data testing

Model	Skema	Drinking&Eating	Phone Use	Sleeping	Smoking
YOLO V5n	1	95.0%	60.0%	96.3%	95.4%
YOLO V8n	1	94.1%	71.9%	94.6%	93.8%
YOLO V10n	1	90.4%	62.9%	93.8%	92.3%
YOLO V5n	2	98.0%	89.8%	95.0%	95.1%
YOLO V8n	2	97.1%	81.6%	95.0%	96.7%
YOLO V10n	2	97.1%	86.8%	93.1%	91.2%

Kelas drinking and eating menunjukkan hasil deteksi paling stabil dan tinggi karena perbedaan visual yang mencolok dengan perilaku normal. Kelas smoking juga dapat dikenali dengan baik karena adanya gerakan tangan dan visual asap. Sebaliknya, kelas phone use sering mengalami kesalahan klasifikasi, terutama saat perangkat yang digunakan kecil atau disembunyikan sebagian. Kelas sleeping menjadi tantangan tersendiri karena kemiripan pose pengemudi yang tertidur dengan posisi istirahat normal, apalagi pada kondisi pencahayaan rendah.

3.3 Konsistensi pada Kondisi Uji

Model YOLOv10n diuji pada berbagai kondisi pencahayaan dan posisi kamera. Hasil menunjukkan performa tetap stabil, dengan hanya sedikit penurunan presisi pada kondisi malam. Hal ini menunjukkan kemampuan generalisasi model cukup baik untuk skenario nyata di lapangan.

```

Ultralytics 8.3.162 Python-3.11.13 torch-2.6.0+cu124 CUDA:0 (Tesla T4, 15095MiB)
val: Fast image access (ping: 0.0±0.0 ms, read: 1158.8±386.0 MB/s, size: 48.5 KB)
val: Scanning /content/skripsi-4/test/labels... 1827 images, 0 backgrounds, 0 corrupt: 100% | 1827/1827 [00:00<00:00, 2376.86it/s]

Class      Images  Instances  Box(P)   R      mAP50  mAP50-95): 100% | 115/115 [00:16<00:00, 6.77it/s]
drinking and eating  440      448      0.905   0.865   0.931   0.548
phone use          479      479      0.901   0.949   0.971   0.608
sleeping          459      472      0.941   0.695   0.868   0.554
smoking           449      449      0.865   0.905   0.931   0.493
               449      449      0.911   0.911   0.953   0.537
Speed: 0.6ms preprocess, 3.9ms inference, 0.0ms loss, 0.3ms postprocess per image
Results saved to runs/detect/train3

```

Figure 1. Evaluasi Testing YOLO V10n Skema 2



Figure 2. Evaluasi testing YOLO V10n Skema 2 (a) Confussion Matrix Testing YOLO V10n Skema 2 (b) Hasil Testing YOLO V10n Skema 2

4. Kesimpulan

Berdasarkan hasil penelitian, diperoleh kesimpulan sebagai berikut:

- YOLOv10n menunjukkan performa yang kompetitif dan seimbang dibandingkan dengan YOLOv5n dan YOLOv8n dalam mendeteksi perilaku berisiko pengemudi.
- Dengan kombinasi akurasi yang tinggi, ukuran model yang kecil, dan kecepatan inferensi yang tinggi, YOLOv10n sangat potensial untuk diterapkan pada sistem pemantauan perilaku pengemudi secara real-time.
- Tantangan utama terletak pada pendeteksian perilaku tidur (sleeping) yang memiliki kemiripan visual dengan kondisi normal, sehingga dibutuhkan teknik lanjutan atau pengayaan data lebih lanjut untuk meningkatkan akurasi klasifikasi.

5. Saran

Penelitian selanjutnya disarankan untuk:

- Menambah variasi data dengan kondisi cuaca ekstrem, kemiringan kamera, dan latar belakang kompleks.
- Menambahkan kategori perilaku lain seperti tidak mengenakan sabuk pengaman atau interaksi dengan penumpang.
- Menguji implementasi model pada perangkat embedded seperti Raspberry Pi atau ESP32-CAM secara langsung.
- Mengembangkan antarmuka pengguna berbasis web atau mobile untuk sistem peringatan dini.
- Mengintegrasikan sistem ini dengan dashboard kendaraan atau sistem ETLE berbasis AI.

6. Referensi

- [1] Badan Pusat Statistik (BPS), "Statistik Transportasi Darat 2023," Jakarta, Indonesia, 2023. <https://www.bps.go.id/id/publication/2024/11/25/cdcf9b5e74dd2e9bb3458ee4/land-transportation-statistics-2023.html>
- [2] M. Chrisnatalia et al., "Perilaku Mengemudi Berisiko," Humanitas, vol. 7, no. 3, pp. 305-318, 2023.
- [3] H. A. Abosaq et al., "Unusual Driver Behavior Detection in Videos Using Deep Learning Models," Sensors, vol. 23, no. 1, pp. 17-18, 2023. doi: <https://doi.org/10.3390/s23010311>
- [4] A. Wang et al., "YOLOv10: Real-Time End-to-End Object Detection," Ultralytics, 2024
- [5] Alzubaidi et al., Review of Deep Learning
- [6] Ultralytics, YOLOv10 Documentation
- [7] IBM, "What is Fine-Tuning?", 2023
- [8] – Y. Liu & K.-D. Kang, "Preprocessing via Deep Learning for Enhancing Real-Time Performance of Object Detection," 2023